

IN GOD WE TRUST
MEDICAL IMAGE PROCESSING COURSE
2022-2023 SPRING SEMESTER

HW04
Image Segmentation

Omid Sharafi
(400201518)

Instructor:
Dr.Emad Fatemizadeh

June 8, 2022



**Sharif
University
of
Technology**



Contents

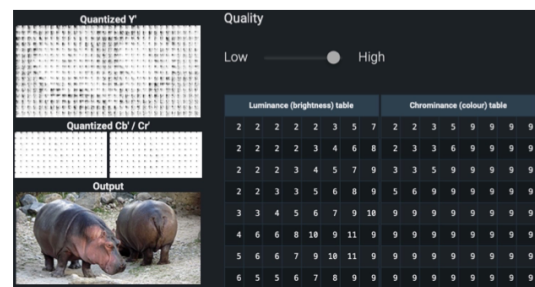
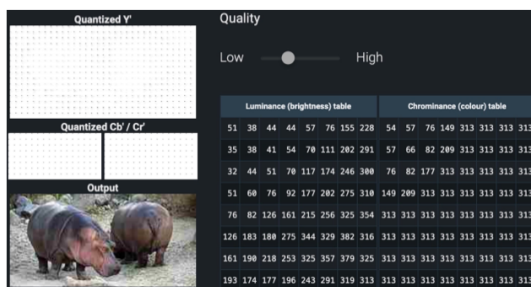
1	Theoretical Problems	2
2	Problem 1	6
2.1	A	6
2.2	B	6
2.3	C	8
2.4	D	10
2.5	E	10
3	Problem 2	12
3.1	A	12
3.2	B	17
4	Problem 3	19
4.1	A	19
4.2	B	23

1 Theoretical Problems

1

الگوی JPEG به این صورت عمل می‌کند که در ابتدا تصویر به سکت‌های ریزشده و کوانتیزه‌ای
رنگی تقسیم می‌شود. در ادامه از کوانتیزه‌ای رنگی یک element-wise می‌کنیم که حجم را کم می‌کند اما کیفیت
میدان به مقدار ناچیز تیره می‌دهد.

در ادامه تصویر را کوانتیزه‌ای رنگی خلاصه می‌کنیم با بلوک‌های 8×8 پیکسل تقسیم کرده و برای هر بلوک
با استفاده از DCT آن را به فضای فرکانسی می‌بریم. در ادامه دو جدول 8×8 کوانتیزاسیون
برای سکت‌های رنگی و رنگ ایجاد کرده که تب با $Quality$ که انتخاب می‌کنیم سکت می‌شود و در ادامه
به تمام بلوک‌های 8×8 هر حوزه فرکانسی را به مقدار مناسب در جدول کوانتیزاسیون تقسیم می‌کنیم.
در ادامه اعداد پس از تقسیم بر این جدول ضرایب به نزدیک‌ترین عدد صحیح رند کرده و در نتیجه به طیف‌ساز
در صورتی که نتیجه سکت زیاد و ضرایب جدول زیاد باشد، ضرایب زیادی از بلوک‌های DCT
صفر می‌شوند و $spare$ می‌شود.




کمیته پایداری، ضرایب تقسیم بالا و ضرایب $spare$

کمیته پایداری، ضرایب جدول و ضرایب $spare$



در نیمه فشرده چینی اعداد فرکانسی در بزرگ 8×8 فرکانسی به صورت zig-zag بوده تا اعداد رابطه به زمانهای فشرده که با اعداد بالا sparse شده و فشرده اند. اینجا ذخیره هر حرکت در نیمه پهنای تکرارهای که در بالا است. از صفا پهنای هر یک از فشرده سازی انجام شود.



همین با فشرده سازی تعداد فشرده سازی به صورت یک عدد به عنوان نمونه تعداد فشرده سازی را انجام داد.


2

در الگوریتم K-SVD هدف پیدا کردن K پایه های Y با حاصل ضرب DX به صورت دیکشنری D ، ماتریس ضرایب X باشد به گونه ای که $\|Y - DX\|_F^2$ را کمینه کرده. X ماتریس sparse باشد. تعداد ستونهای نامزد هر ستون کمتر از یک مقدار ثابت به عنوان ضرایب اولیه از قبل تعیین شده τ_i و λ_i و γ_i برابر باشد.

حال برای پیدا کردن پایه های بهینه سازی الگوریتم در مرحله انجام می شود. در ابتدا با فرض اولیه D ماتریس sparse ضرایب X را با روشی ای فلت مانند orthogonal matching pursuit انتخاب می کنیم. در ادامه برای آپدیت ماتریس D ، به صورت ستون به ستون می رویم. به این منظور برای آپدیت ستون k -ام.

$$\|Y - DX\|_F^2 = \left\| Y - \sum_{j=1}^K d_j x_j^T \right\|_F^2 = \left\| \left(Y - \sum_{j \neq k} d_j x_j^T \right) - d_k x_k^T \right\|_F^2 \quad \text{دلیل:}$$

در نیمه برای حل این مسئله به سادگی می توانیم از SVD استفاده کنیم. به سادگی در اینجا این است که با SVD ماتریس D را به دو ماتریس ضرایب X از حالت sparse که



در فضای 64 بعدی 100 ام حایه در نظر گرفته ایم، با توجه به آن که 100 ام حایه
تک مف است، ممکن است ترکیبی از 100 ام حایه که انتخاب کرده ایم بسته نباشد، فرض
آن که هیچ حایه ای در فضای بعدی از 4 قرار نگیرد، همان گت زیرضا (100) خواهد بود
ترکیبی ایجاد شده بسته خواصه بود.



4

ماتریس دیکری ما به صورت $D = \begin{pmatrix} 1 & 0 & 1 & 1 \\ 2 & 1 & 1 & 0 \end{pmatrix}$ بوده و مدینه برای بازسازی $y = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$ همان
از بازسازی ای حالت $x = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \end{pmatrix}$ ، $x = \begin{pmatrix} 2 \\ 2 \\ 0 \\ 0 \end{pmatrix}$ ، ... استانه که آن sparse کتب بازسازی برابر با :
می باشد. $y = D \begin{pmatrix} 2 \\ 2 \\ 0 \\ 0 \end{pmatrix}$

5

الگوریتم Basis pursuit میله بیهازی $y = Ax$ s.t. $\min_x \|x\|_1$ را $x \in \mathbb{R}^n$ ،
می باشد $y \in \mathbb{R}^m$ ، $A \in \mathbb{R}^{m \times n}$ عنوان جابجایی میله بیهازی که زیر استانه می گردد.
 $\min_{D, x} \sum_i \|x_i\|_0$ s.t. $\|y - Dx\|_F^2 \leq \epsilon$

الگوریتم Matching Pursuit برای حل میله بیهازی که $\|x\|_0 \leq T_0$ s.t. $\|y - Dx\|_2^2$ را
استانه می گردد که در مثال دوم نیز توضیح داده شد. در این روش هدف پیدا کردن بهترین تخمین است. و آن از
پیدا کردن x براساس ستن ای ماتریس دیکری D می باشد. به روشی که به صورت تکرار شونده با شروع
از $r = y$ شروع کرده و در هر مرحله $r^* = \arg \min_j \frac{|\langle r, d_j \rangle|}{\|d_j\|_2}$ where $d_j = \langle r, d_j \rangle - \langle r, d_j \rangle \frac{d_j}{\|d_j\|_2}$ و $r^{i+1} = r^i - \langle r^i, d_{j^*} \rangle \frac{d_{j^*}}{\|d_{j^*}\|_2}$
تکرار می گردد.



در میله بیهازی basis pursuit بهترین تخمین y با ماتریس دیکری D بوده که این روش را می توان به روشی $\|x\|_1$ در زمان شد
بودن آن ندارد. یعنی روشی matching pursuit با دقت به آن که روشی حریفانه می شود و تکرار شونده استانه می شود.
میکنی است طریقه بازسازی بالا را می توان به روشی sparse بودن تابع کنترل می باشد.



2 Problem 1

2.1 A

Based on the results below, 3 and 4 classes are good for image segmentation.



In the following parts, we will use 4 classes.

2.2 B

In the below image, first row is four original images. The second row is segmentation result for $FC = 1.1$. The third row is for $FC = 2$ and regions are more smoother than first row. The last row is result of segmentation of $FC = 5$.




Figure 1: FCM Segmentation

The number of iteration and final objective function for each FC is shown below. Iteration number is increasing based on the FC and objective value is decreasing.

FCM :
Fuzzy coefficient : 1.100000e+00
Number of iteration : 23
Objective Function : 2.784911e+03

FCM :
Fuzzy coefficient : 2
Number of iteration : 36
Objective Function : 1.546316e+03

FCM :
Fuzzy coefficient : 5
Number of iteration : 48
Objective Function : 3.771187e+01



2.3 C

Both 3 and 4 classes results are good. But using K-means result as the FCM initial condition, we get following results.

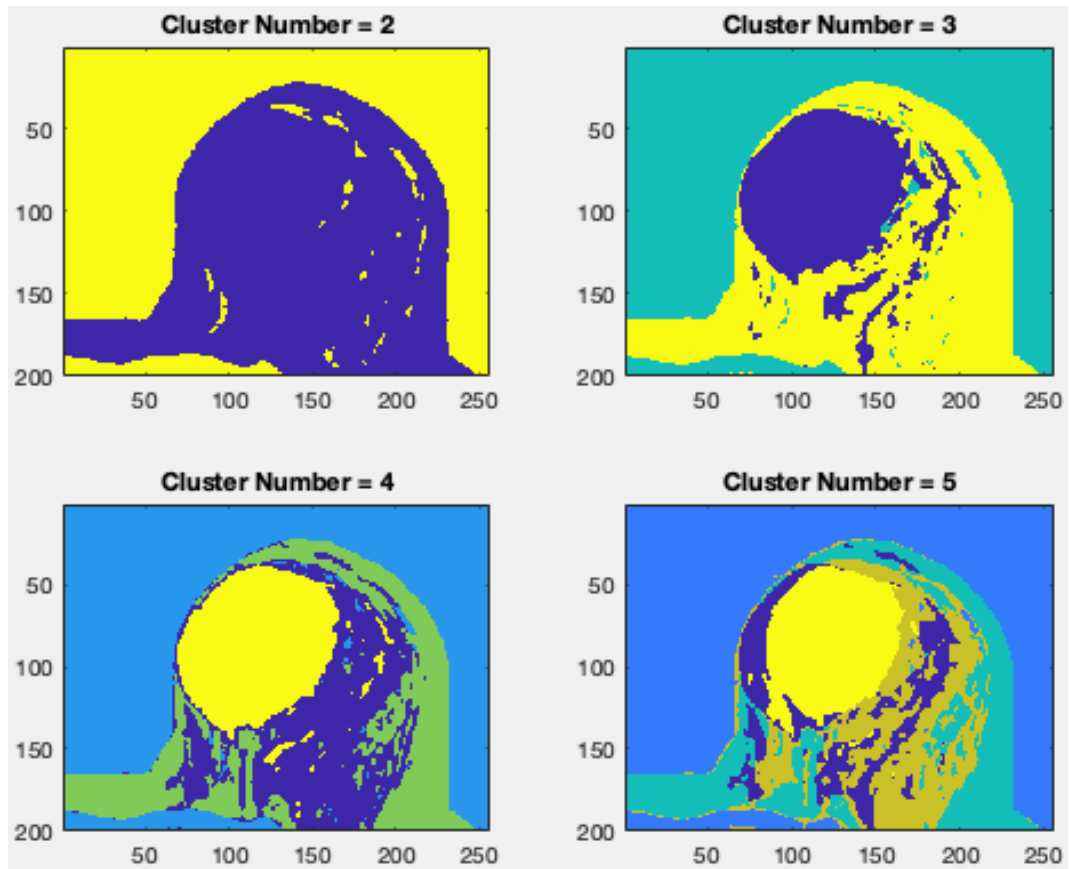


Figure 2: K-means Segmentation




Figure 3: FCM Segmentation

The final results are as same as the previous part. But when we use supervised initial condition, the number of iteration decrease.

```
FCM with initial condition:  
Fuzzy coefficient : 1.100000e+00  
Number of iteration : 19  
Objective Function : 2.784911e+03
```

```
FCM with initial condition:  
Fuzzy coefficient : 2  
Number of iteration : 15  
Objective Function : 1.546316e+03
```

```
FCM with initial condition:  
Fuzzy coefficient : 5  
Number of iteration : 21  
Objective Function : 3.771187e+01
```

2.4 D

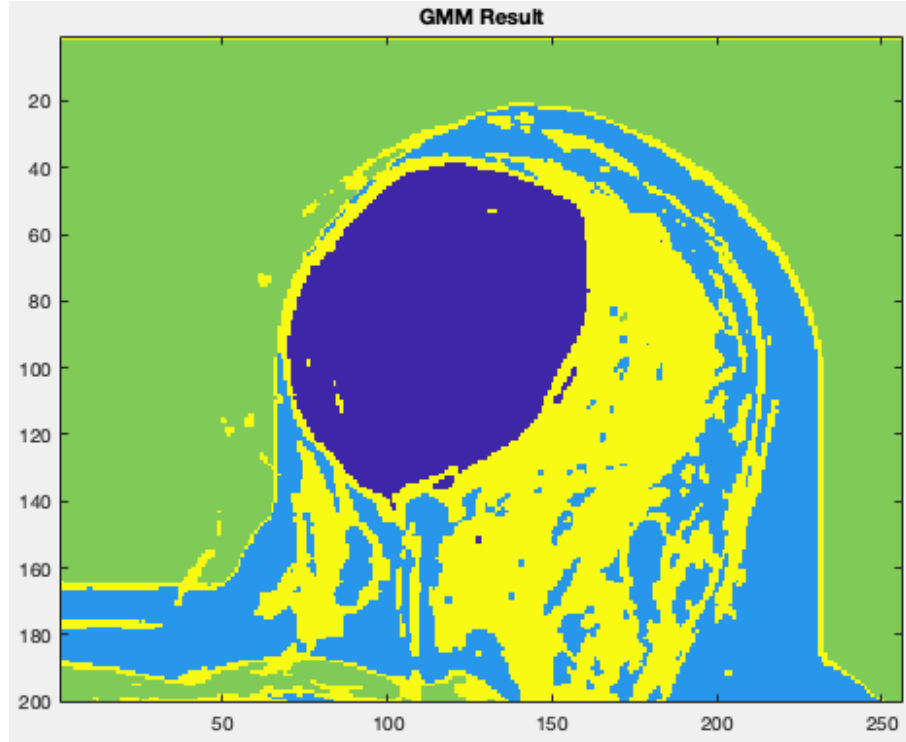


Figure 4: GMM method result

2.5 E

For calculating partial volume I defined a metric. We know that partial volumes are parts that their relation to the particular class is not so higher than other parts. It means that maximum value in their probability vector is not high. But what does high mean here? For adjusting threshold we have two constraints. First, if we have for example 4 classes, then some number around $1/4$ is appropriate to be one of the threshold as it is the ground truth. So we used $1.25/Numberofclasses$ as first metric. The second metric relates to the FC. As FC increase, the probability vector elements become more normal. So we set $1/FC$ as our second metric and maximum of these two number is the limit. The pixels that the maximum number in their probability vector is less than the limit considered as the picture partial volume.




Figure 5: MRI Partial Volume

s

As you can see in figure 5, partial volume are more appear in intersection of different classes. This result is logical, because in these areas the elements of probability vector is not sparse and the pixels can be considered in different classes.



3 Problem 2

3.1 A

The results of melanoma and nevus segmentation using both GVF and basic snake approaches are shown below.

In the term of comparison, both methods work for both images. But in overall, GVF works smoother and easier than snake method. In snake method you should first set the initial contour. The algorithm is highly sensitive to initial contour and its parameters. So for example, for melanoma image that the skin lesion shape is not convex, it was really hard to adjust the parameters in a way that the contour converge and wrap over the lesion. But in the term of final result, if you can set the snake parameters well, the final segmentation result will be good.

2. Firstly, the user selects the image and selects the σ values for the Gaussian smoothing.
3. Then user selects the initial position of the snake by clicking on the image and selecting control points which are later interpolated (Spline based) into a contour.
4. The user specifies various control parameters for the snake. These include
 - α (alpha): Specifies the elasticity of the snake. This controls the tension in the contour by combining with the first derivative term.
 - β (beta): Specifies the rigidity in the contour by combining with the second derivative term.
 - γ (gamma): Specifies the step size
 - κ (kappa): Acts as the scaling factor for the energy term.
 - $W(E_{\text{line}})$: Weighing factor for intensity based potential term.
 - $W(E_{\text{edge}})$: Weighing factor for edge based potential term.
 - $W(E_{\text{term}})$: Weighing factor for termination potential term.

Figure 6: Basic snake approach parameters

On the other hand, the GVF method runs so easily. But the GVF method works based its gradient u and v field, so when you want to find the boarder based on the field magnitude, it may become thick, you may find some boarder that are not related to our lesion, and there is no guarantee that our final border is continues. In snake method the contour has close shape in all algorithm steps.




Figure 7: GVF method result




Figure 8: GVF (u,v) field map




Figure 9: Initial contour of snake

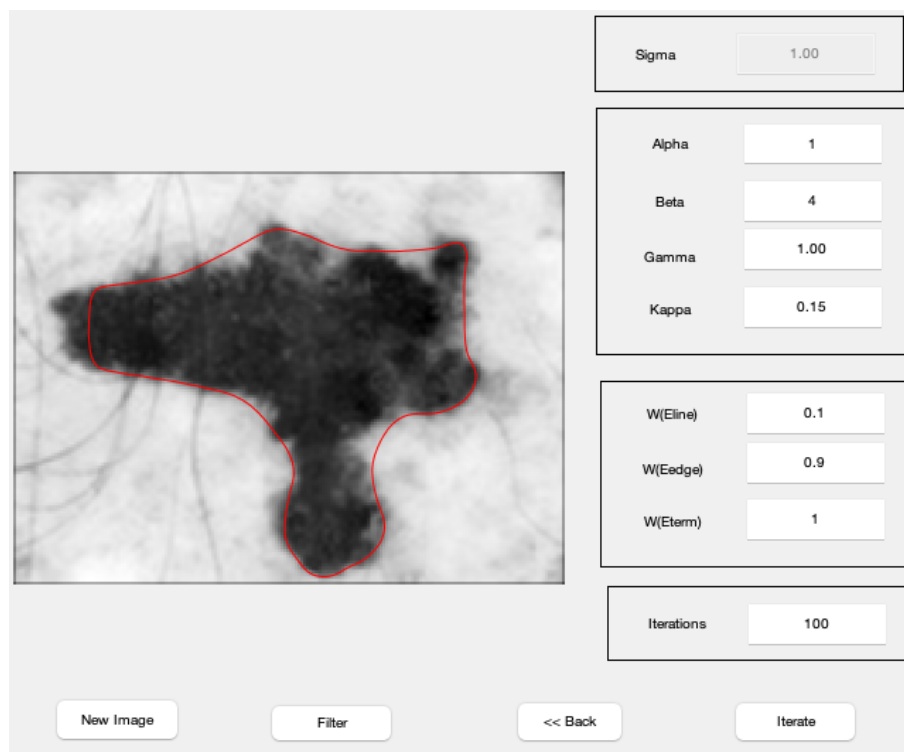


Figure 10: Final snake state




Figure 11: GVF method result




Figure 12: GVF (u,v) field map




Figure 13: Initial contour of snake




Figure 14: Final snake state

3.2 B

We used both methods on MRI1 image. Because of the convex shape of the tumor and its contrast, the snake method works so well.




Figure 15: GVF method result




Figure 16: GVF (u,v) field map

The GVF method gives us the field and we can calculate borders using its magnitude, so we can segment separated parts by this method. But snake method is based on a closed snake contour, so we can just segment one connected area.




Figure 17: Initial contour of snake




Figure 18: Final snake state

4 Problem 3

4.1 A




Figure 19: Initial user-defined mask

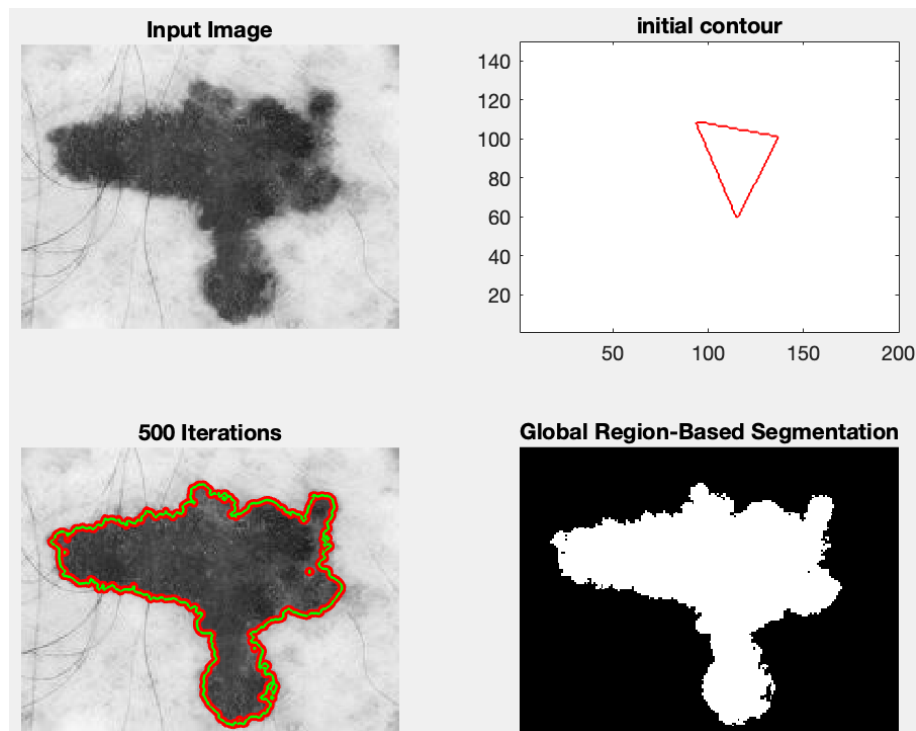


Figure 20: Final Chan-vee result




Figure 21: Initial user-defined point

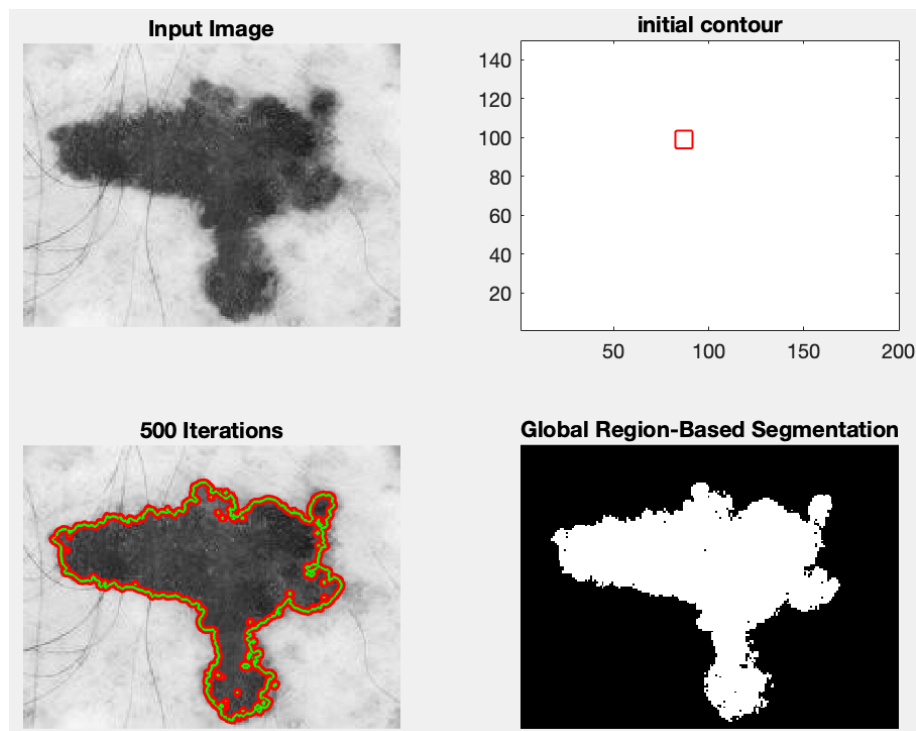


Figure 22: Final Chan-veese result




Figure 23: Initial user-defined mask

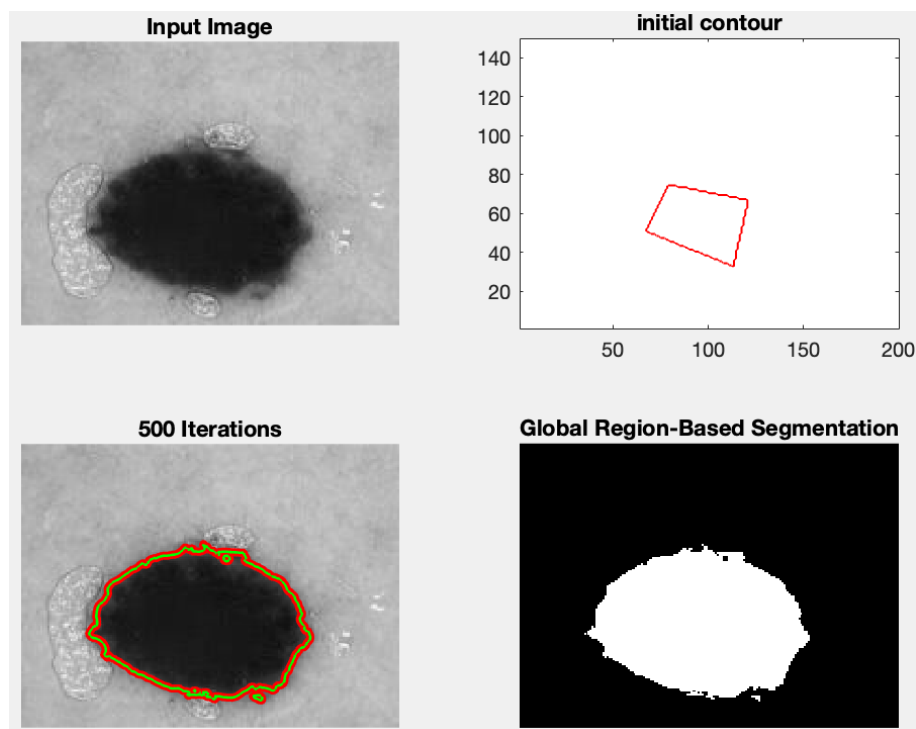


Figure 24: Final Chan-vee result




Figure 25: Initial user-defined point

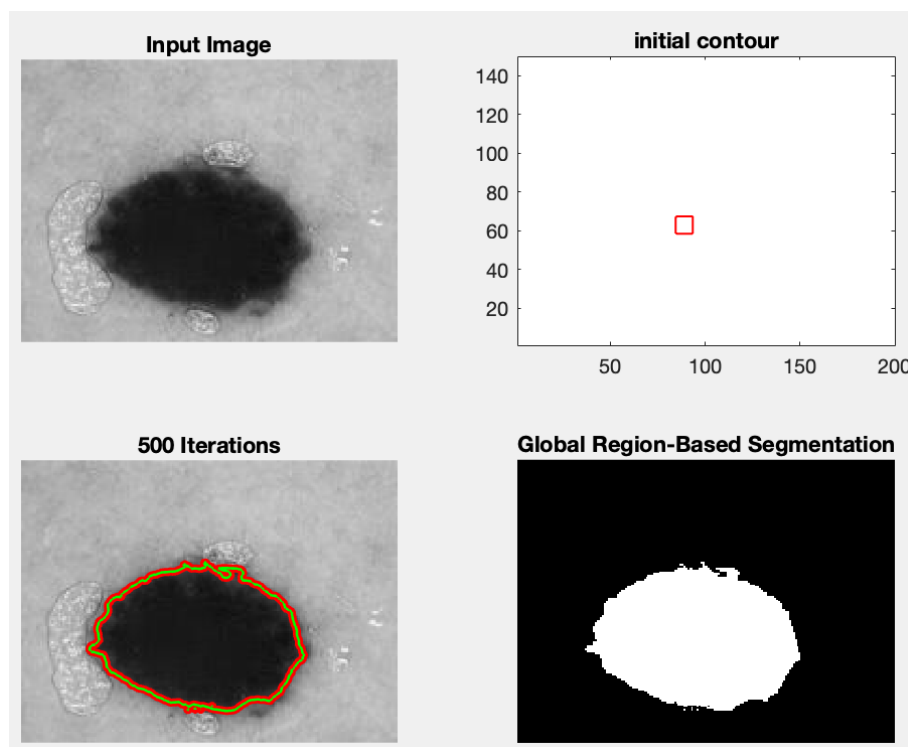


Figure 26: Final Chan-vee result

4.2 B




Figure 27: Initial user-defined mask

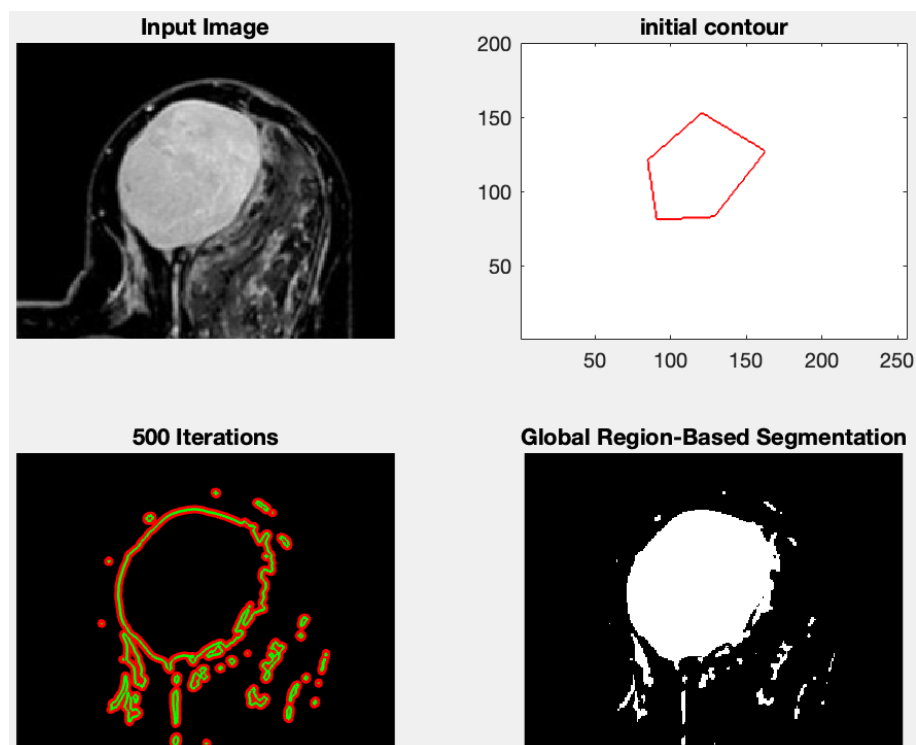


Figure 28: Final Chan-vee result




Figure 29: Initial user-defined point

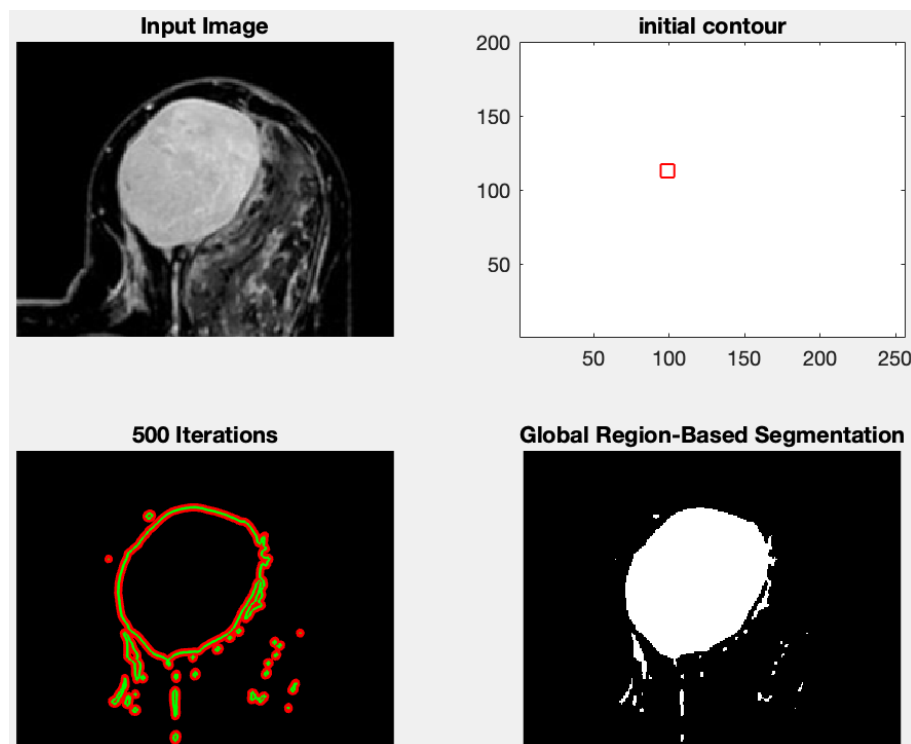


Figure 30: Final Chan-vee result

The robustness of Chan-Vest method is awesome. When you initial the method using just 9×9 kernel or draw a triangle or more complex polygon, the method works perfectly. The difference of this method from previous part results on MRI image is that this algorithm considers some other parts of the image that have same color as the main tumor part.

For automating the method, we fist applied 21×21 median kernel on the image. Then we selected one of the result peak points as center of the initial rectangular kernel. As we know that tumor is more brighter than other parts, the most bright kernel that we select will be on the tumor area. So the method will work properly by selecting initial contour using this algorithm. The result is shown below.

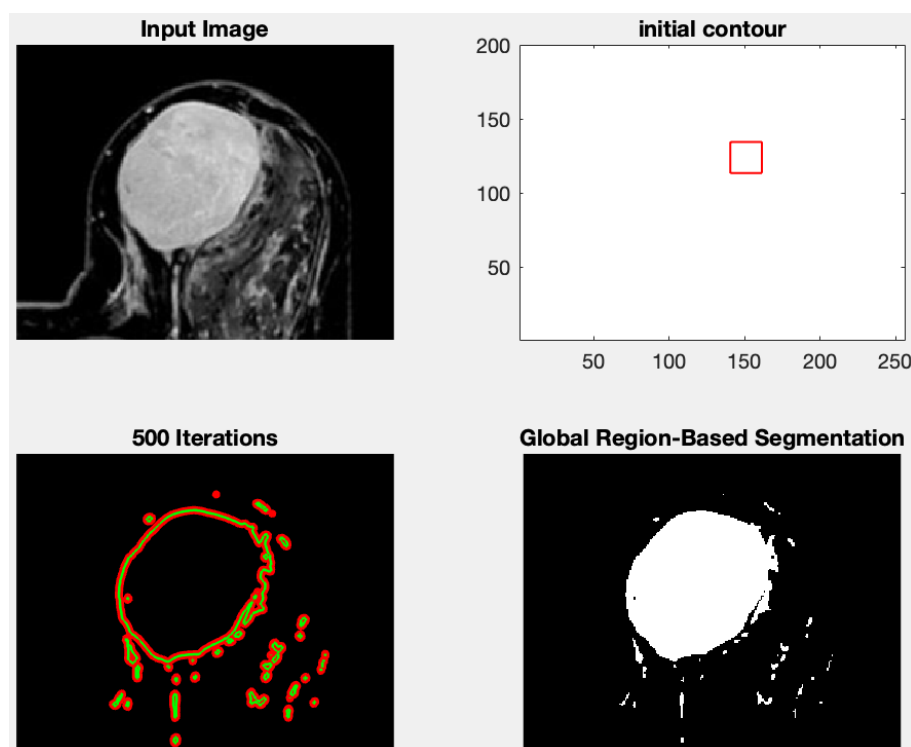


Figure 31: Auto Chan-veste result based on brightness